

Primera Entrega de Proyecto



Gabriel Jaramillo
Juan Felipe Gómez
David Felipe Vargas
Sara Pulgarín
Juan Camilo Delgado

Procesamiento de Datos a Gran Escala (1255)

Docente: John Jairo Corredor Franco

Índice

Índice	2
1. Entendimiento del negocio	3
2. Selección de los datos a utilizar	5
3. Colección y descripción de los datos	7
4. Exploración de los datos	10
5. Reporte de calidad de datos	14
6. Planteamiento de preguntas sobre los datos	17
7. Filtros, limpieza y transformación inicial.....	18
8. Desarrollo de los bonos	20
9. Conclusiones	22
10. Referencias	24

1. Entendimiento del negocio

1.1 Contexto General de Nueva York

Nueva York es una de las ciudades más grandes y densamente pobladas de Estados Unidos. Con aproximadamente **8.48 millones de habitantes** distribuidos en cinco distritos (Bronx, Brooklyn, Manhattan, Queens y Staten Island), la ciudad concentra una presión enorme sobre sus sistemas de seguridad pública y movilidad. Los desafíos de gestionar una ciudad de esta escala se reflejan en sus indicadores socioeconómicos. A nivel de ciudad, según el “2025 Income and Affordability Study” en New York más de una cuarta parte de la población vive por debajo del umbral de pobreza suplementario y un 33% más de Neoyorkinos fueron clasificados en el reporte como “en pobreza” e “ingresos bajos”, y las tasas más altas se concentran en distritos periféricos como el Bronx.

Este contexto importa porque la literatura urbana sugiere que las zonas con mayor presión económica suelen coincidir con las áreas de mayor incidencia de problemas de seguridad y siniestralidad vial. El gobierno del Estado de Nueva York ha identificado dos indicadores como prioritarios para la acción pública:

Primero, los accidentes viales. A pesar de que la ciudad implementó en 2014 la política Vision Zero con el objetivo de reducir las muertes y lesiones graves asociadas al tránsito, la seguridad vial continúa siendo un desafío. Durante los primeros meses de 2026 se registraron en la ciudad 30.179 colisiones, 12.241 personas heridas y 70 fallecidas. Además, estos eventos no se distribuyen de manera uniforme entre los distintos territorios, ya que Brooklyn concentra aproximadamente el 30% de los accidentes registrados, mientras que Queens representa cerca del 16% de la ciudad.

Segundo, los arrestos. El volumen de arrestos permite aproximarse a la intensidad de la actividad policial y observar diferencias en las dinámicas de seguridad entre los distintos territorios de la ciudad. Los datos abiertos de Nueva York permiten analizar su distribución territorial, temporal y demográfica, así como estudiar posibles asociaciones con otros indicadores socioeconómicos. Este análisis puede aportar evidencia para orientar la asignación de recursos, fortalecer las estrategias de prevención y apoyar la toma de decisiones en materia de seguridad pública.

Dentro de este panorama, el gobierno ha encomendado al equipo consultor la identificación de patrones territoriales y factores asociados a los arrestos y a los siniestros viales, con el propósito de generar evidencia que permita priorizar las intervenciones públicas. El análisis no busca limitarse a una descripción general de la ciudad, sino identificar en qué territorios se concentran estos fenómenos, cómo se distribuyen las condiciones socioeconómicas, especialmente la pobreza, y qué otros elementos contextuales pueden contribuir a orientar una actuación pública más focalizada. Además, es importante destacar que, aunque el caso de negocio plantea al Estado de Nueva York como contratante del equipo consultor, el alcance

territorial de este proyecto se concentra en New York City, debido a que las principales fuentes proporcionadas corresponden a registros administrativos y socioeconómicos de la ciudad.

1.2 Objetivo del negocio

El gobierno dispone de diferentes fuentes de información relacionadas con seguridad pública, seguridad vial y condiciones socioeconómicas. Sin embargo, la existencia de estos registros no implica por sí misma que la información pueda utilizarse directamente para orientar decisiones de gestión pública.

Los datos presentan diferentes estructuras, unidades de observación, períodos de referencia y niveles de desagregación. Por esta razón, antes de utilizarlos para la toma de decisiones es necesario realizar procesos de integración, limpieza, transformación y análisis que permitan convertir los registros disponibles en indicadores territoriales comparables.

El problema de negocio consiste, por tanto, en transformar diferentes fuentes de datos en información analítica que permita reconocer diferencias entre los territorios de New York City, identificar patrones relevantes y establecer criterios que apoyen la focalización de posibles intervenciones relacionadas con la seguridad pública y vial.

En particular, se busca evitar que la toma de decisiones se base únicamente en cantidades absolutas. Un distrito con mayor población puede presentar una cantidad elevada de arrestos o colisiones simplemente debido a su tamaño poblacional. Por ello, el proyecto contempla la construcción de indicadores normalizados y la incorporación de variables socioeconómicas que permitan obtener una caracterización territorial más completa.

Por esta razón, el objetivo de negocio del proyecto es fortalecer la capacidad del gobierno de New York City para focalizar territorialmente sus intervenciones de seguridad pública y vial mediante la identificación y caracterización de patrones espaciales y temporales de arrestos y colisiones, complementados con el análisis de las condiciones socioeconómicas de los territorios.

Para alcanzar este objetivo se desarrollará un diagnóstico territorial correspondiente al año base seleccionado, 2018, mediante la integración de las diferentes fuentes de información disponibles. El resultado esperado es una caracterización de los cinco distritos de New York City que permita identificar diferencias en los indicadores analizados y proporcionar evidencia para orientar posteriormente un plan de acción territorial.

Adicionalmente, se establecen los siguientes objetivos analíticos:

1. Identificar concentraciones, patrones y comportamientos diferenciados de los indicadores según territorio, período y características de los eventos, con el propósito de determinar si existen zonas o períodos que presenten comportamientos significativamente diferentes del resto de la ciudad.
2. Analizar la relación entre los indicadores de seguridad y las características socioeconómicas y contextuales de los territorios, especialmente las relacionadas con pobreza y educación, sin asumir previamente la existencia de relaciones causales.
3. Establecer criterios basados en evidencia que permita identificar territorios que puedan ser requerir mayor atención dentro de las estrategias de intervención pública.
4. Proponer un plan de acción territorial que traduzca los hallazgos del análisis en recomendaciones para la gestión pública y en mecanismos para el seguimiento de los indicadores.

2. Selección de los datos a utilizar

Para el desarrollo del proyecto se seleccionaron conjuntos de datos relacionados con tres dimensiones principales. La primera corresponde a la seguridad pública, representada mediante los registros de arrestos. La segunda corresponde a la seguridad vial, analizada a partir de los registros asociados a colisiones y vehículos involucrados. La tercera corresponde al contexto socioeconómico de la población, para lo cual se utilizan variables relacionadas con pobreza y educación.

La selección de estas fuentes responde directamente al objetivo de negocio planteado. Los datos de arrestos y accidentes permiten caracterizar los dos indicadores señalados como prioritarios dentro del caso de negocio, mientras que las variables socioeconómicas permiten ampliar el análisis y estudiar si existen diferencias en las condiciones de los territorios que puedan estar asociadas con el comportamiento de estos indicadores.

2.1 Datos de arrestos

El conjunto de datos de arrestos del New York City Police Department (NYPD) fue seleccionado como fuente principal para analizar la dimensión de seguridad pública. Cada registro representa un arresto e incluye información relacionada con la fecha del evento, el territorio donde ocurrió, la categoría de la infracción y algunas características demográficas asociadas al registro.

Su incorporación al proyecto permite estudiar cómo se distribuyen los arrestos entre los diferentes territorios de Nueva York y reconocer posibles patrones relacionados con el periodo, el tipo de infracción y las características de los registros.

El conjunto también permite generar agregaciones territoriales que posteriormente pueden ser utilizadas para construir indicadores comparables entre zonas. Sin embargo, durante la

exploración de los datos se identificó que hay data sets que tienen datos hasta el 2018, por lo cual se plantea como año objetivo.

2.2 Datos de colisiones y accidentes viales

La segunda fuente corresponde al conjunto de datos de Motor Vehicle Collisions - Vehicles. Es importante señalar que la unidad de observación de este conjunto de datos es el vehículo involucrado en una colisión, y no directamente el accidente. Por esta razón, el número de filas del dataset no puede interpretarse automáticamente como cantidad de accidentes.

En este orden de ideas, para construir el indicador de cantidad de colisiones se utilizará el identificador de la colisión (COLLISION_ID), de manera que cada evento sea contabilizado una sola vez. Así, se distinguirán los conceptos de cantidad de vehículos involucrados (número de registros del conjunto de datos) y de cantidad de colisiones (número de identificadores de colisión únicos). Esta distinción resulta fundamental para evitar una sobreestimación del indicador de accidentes.

El conjunto permite analizar la frecuencia de colisiones mediante COLLISION_ID, así como las características de los vehículos involucrados, los factores contribuyentes y los patrones temporales.

2.3 Datos de pobreza y educación

El conjunto de datos, correspondientes a pobreza y educación, son microdatos de New York City que se utilizará para incorporar una dimensión socioeconómica al diagnóstico territorial. Para pobreza se utilizará PWGTP y, para educación, se utilizará EducAttain, restringiendo el análisis a personas de 25 o más años y a registros con pesos válidos.

Una característica importante de esta fuente es la presencia de la variable PWGTP, correspondiente al factor de ponderación de cada registro. Debido a la naturaleza muestral de los datos, las observaciones no necesariamente representan a una sola persona de la población. Por esta razón, para determinadas estimaciones se utilizarán los factores de ponderación en lugar de realizar únicamente conteos simples de registros, como lo es PWGTP, que permitirán realizar agregaciones ponderadas y aproximarse de mejor manera a la población representada por los registros disponibles.

Durante la preparación de los datos se identificaron valores nulos, cero o negativos en esta variable. Debido a que estos valores no resultan adecuados para las agregaciones ponderadas utilizadas en el proyecto, serán excluidos de los cálculos correspondientes y su cantidad será reportada dentro del análisis de calidad de datos.

2.4 Datos de población

Para la construcción de indicadores territoriales normalizados se requiere disponer de un denominador poblacional correspondiente al mismo territorio y período que los eventos analizados. Por esta razón, se incorporan fuentes obtenidas mediante técnicas de extracción automatizada de información pública.

Una de las fuentes permite obtener directamente la población correspondiente a los cinco boroughs de New York City para 2018, generando un archivo JSON con un registro por distrito. Adicionalmente, se dispone de una fuente que contiene información poblacional para el Estado de Nueva York, de la cual se seleccionan únicamente los registros correspondientes a New York City.

Estas fuentes tienen como función principal proporcionar el denominador poblacional para la construcción de tasas territoriales. No sustituyen los microdatos de pobreza ni constituyen una medida de pobreza.

2.5 Datos climáticos

Como fuente complementaria se plantea incorporar información climática correspondiente al período de análisis, con el propósito de explorar su posible asociación con la ocurrencia y características de las colisiones viales.

La inclusión de esta dimensión responde a la hipótesis de que determinadas condiciones meteorológicas podrían estar asociadas con variaciones en la frecuencia o características de los eventos viales. Entre las variables potencialmente relevantes se encuentran condiciones como precipitación, temperatura, visibilidad u otras medidas meteorológicas disponibles.

Esta fuente tendrá inicialmente un carácter exploratorio. La existencia de una asociación estadística entre condiciones climáticas y colisiones no será interpretada automáticamente como evidencia de causalidad.

2.6 Criterio temporal

El proyecto adopta 2018 como año base para el diagnóstico histórico de New York City, principalmente debido a la disponibilidad de información socioeconómica y poblacional compatible con dicho período.

3. Colección y descripción de los datos

El procesamiento de los conjuntos de datos se realiza mediante un clúster de Apache Spark configurado por el equipo de consultoría. Las características específicas del clúster utilizadas durante el procesamiento son:

- Número de nodos: 6 workers
- Memoria disponible: 14,3 GiB por worker (86 GiB en total)
- Número de núcleos: 4 núcleos por worker (24 en total); cada aplicación del equipo se limita explícitamente a un máximo de 2 núcleos para no acaparar los recursos compartidos.
- Versión de Spark: 4.2.0
- Versión de Python/PySpark: Python 3.11.13 / PySpark 4.2.0
- Sistema o plataforma utilizada: clúster Apache Spark en modo standalone, desplegado sobre máquinas virtuales de la universidad, con acceso mediante un servidor Jupyter Notebook y un kernel dedicado (Python 3.11 - Spark)

El procesamiento fue organizado en cuatro notebooks principales:

1. Procesamiento y preparación de datos de arrestos.
2. Procesamiento y preparación de datos de colisiones.
3. Procesamiento de datos de pobreza y educación.
4. Integración de los resultados para construir indicadores territoriales.

Esta separación permite trabajar cada fuente de acuerdo con sus características particulares antes de realizar la integración final.

3.1 Datos de arrestos

La unidad básica de observación del conjunto de arrestos es el registro de un arresto.

Entre las variables relevantes se encuentran aquellas relacionadas con:

- fecha del arresto.
- distrito o borough.
- categoría del delito.
- características demográficas.
- información geográfica disponible.

La descripción definitiva de cada atributo se incorporará a partir del esquema obtenido directamente desde Spark.

- Número de registros iniciales: 917 (correspondientes únicamente a diciembre de 2018, único período disponible en el archivo recibido)
- Número de variables: 19 (arrest_key, arrest_date, pd_cd, pd_desc, ky_cd, ofns_desc, law_code, law_cat_cd, arrest_boro, arrest_precinct, jurisdiction_code, age_group, perp_sex, perp_race, x_coord_cd, y_coord_cd, latitude, longitude, lon_lat)

- Período disponible: diciembre de 2018 (01/12/2018 a 31/12/2018), sin fechas no interpretables

3.2 Datos de colisiones

El conjunto de datos de vehículos contiene información sobre los vehículos involucrados en colisiones. Por tanto, la unidad de observación corresponde a un vehículo asociado a un evento de colisión.

Entre las variables relevantes se encuentran:

- identificador de la colisión.
- fecha del evento.
- Ubicación.
- información sobre el vehículo.

Para el análisis de la cantidad de accidentes se utilizará el identificador único de la colisión, evitando contabilizar varias veces un mismo evento debido a la presencia de varios vehículos.

- Número de registros iniciales: 4.551.002 filas de vehículos en el archivo histórico completo; 465.822 filas corresponden al año objetivo 2018, equivalentes a 231.542 colisiones identificables mediante COLLISION_ID
- Número de variables: 25 (unique_id, collision_id, crash_date, crash_time, vehicle_id, state_registration, vehicle_type, vehicle_make, vehicle_model, vehicle_year, travel_direction, vehicle_occupants, driver_sex, driver_license_status, driver_license_jurisdiction, pre_crash, point_of_impact, vehicle_damage, vehicle_damage_1, vehicle_damage_2, vehicle_damage_3, public_property_damage, public_property_damage_type, contributing_factor_1, contributing_factor_2)
- Período disponible: 2012 a 2026 en el archivo completo; el año objetivo 2018 concentra 465.822 registros de vehículos

3.3 Datos de pobreza

Los datos socioeconómicos contienen información individual y territorial que permite caracterizar las condiciones de la población. Una de las variables centrales es PWGTP, utilizada como factor de ponderación. Esta variable será considerada durante las agregaciones relacionadas con población y pobreza. Además, para el análisis educativo se aplicará el filtro de edad correspondiente a personas de 25 años o más.

- Número de registros iniciales: 68.273 personas de la muestra, que representan (mediante el factor de ponderación PWGTP) 8.218.313 personas de la población de NYC en 2018
- Número de variables: 61, entre las que se incluyen SERIALNO y SPORDER (identificadores de hogar y de persona), PWGTP (factor de ponderación), AGEP (edad), BORO (distrito), EDUCATTAIN (nivel educativo) y NYCGOV_POV_STAT (estado de pobreza, entre otras variables de ingreso y gasto estimado)
- Período disponible: 2018 (año fijo de la fuente NYCgov Poverty Measure Data), con edades registradas entre 0 y 95 años

3.4 Integración territorial

Una vez procesadas individualmente las fuentes, se plantea construir una tabla consolidada a nivel de distrito. La unidad final de análisis será el borough de New York City:

- Bronx;
- Brooklyn;
- Manhattan;
- Queens;
- Staten Island.

La tabla integrada se diseñará para reunir, a nivel territorial, los indicadores disponibles y compatibles entre las diferentes fuentes. La integración verificará previamente la cobertura temporal, las claves territoriales y la disponibilidad de cada indicador, conservando valores nulos cuando una fuente no permita calcular un indicador para determinado territorio o período.

El objetivo de esta integración es construir una base que permita comparar las características de los territorios y posteriormente identificar aquellos que presenten combinaciones relevantes de los indicadores estudiados.

4. Exploración de los datos

A continuación, se presentan los principales elementos de exploración descriptiva realizados sobre los tres conjuntos de datos, obtenidos directamente a partir de las agregaciones calculadas en el clúster de Spark. Se incluyen ocho elementos de análisis: estadísticos descriptivos, tablas agregadas y distribuciones por categoría, que permiten entender la estructura y el comportamiento de los datos antes de la integración territorial.

4.1 Arrestos por distrito en 2018

Con los 917 registros de arrestos de diciembre de 2018 ya depurados, se agregaron los eventos por distrito. Brooklyn concentra el mayor número de arrestos en términos absolutos, seguido de Bronx, Manhattan, Queens y, muy por debajo, Staten Island (ver Figura 1).



Figura 1. Cantidad de arrestos según el distrito

4.2 Arrestos por grupo de edad, 2018

La exploración demográfica de los arrestos de diciembre de 2018 se realizó agrupando los registros por la variable `age_group`, lo que permite identificar qué rangos de edad concentran una mayor proporción de los eventos registrados, información relevante para caracterizar el perfil de los arrestos antes de vincularlos con otras variables socioeconómicas. En este caso, como muestra la Figura 2, encontramos que la mayor cantidad de arrestos se sitúan en el rango de 25 a 44 años.




Figura 2. Cantidad de arrestos según grupo etario

4.3 Calidad y cobertura del archivo de vehículos

El archivo de Motor Vehicle Collisions - Vehicles contiene 4.551.002 filas en total, distribuidas entre 2012 y 2026. Filtrando únicamente el año objetivo, 2018 concentra 465.822 registros de vehículos (detallados en la Figura 3), correspondientes a 231.542 colisiones identificables mediante COLLISION_ID. Esta distinción entre filas de vehículos y colisiones únicas es la que se utiliza en todo el proyecto para evitar sobreestimar la cantidad de accidentes.




Figura 3. Tipos de vehículos identificados en las colisiones

4.4 Vehículos involucrados por colisión, 2018

Al agrupar las 231.542 colisiones identificables según el número de vehículos asociados, la gran mayoría corresponde a colisiones de dos vehículos, como podemos observar en la Figura 4; los casos de un solo vehículo y de tres o más vehículos son considerablemente menos frecuentes.




Figura 4. Cantidad de vehículos involucrados en las colisiones

4.5 Disponibilidad de factores contribuyentes reportados, 2018

De los 465.822 registros de vehículos de 2018, 216.775 (46,5%) tienen un factor contribuyente informado, 229.861 (49,3%) quedaron registrados como “Unspecified” (no especificado) y 19.186 (4,1%) no tienen ningún dato en este campo (ver Figura 5). Esto significa que, aunque el campo rara vez está vacío, casi la mitad de los registros no aporta información útil sobre la causa de la colisión, una limitación relevante para responder las preguntas de negocio relacionadas con factores contribuyentes.




Figura 5. Cantidad de registros según información adicional reportada

4.6 Estructura por edad y nivel educativo de la población, 2018

Sobre las 8.218.313 personas representadas por la muestra de pobreza (68.273 registros ponderados mediante PWGTP), se calculó la distribución del nivel educativo alcanzado por la población de 25 años o más. La categoría con mayor peso poblacional es “Bachelor o superior”, seguida de “Secundaria completa”, “Estudios superiores sin bachelor” y, en menor proporción, “Menos de secundaria”.

Nivel educativo	Cantidad estimada de personas
Menos de secundaria	989.510
Secundaria completa	1.369.308
Estudios superiores sin bachelor	1.165.451
Bachelor o superior	2.311.592

4.7 Pobreza y educación por distrito, 2018

Al desagregar por distrito, tanto la tasa de pobreza como la proporción de personas sin secundaria completa son sistemáticamente más altas en el Bronx, y sistemáticamente más bajas en Manhattan. Brooklyn, Queens y Staten Island se ubican en posiciones intermedias entre esos dos distritos.

Distrito	Pobreza (%)	Sin secundaria, 25+ (%)
Bronx	27,10	26,26
Brooklyn	20,31	16,42
Manhattan	15,06	11,67
Queens	17,02	17,32
Staten Island	16,00	12,17

4.8 Integración territorial preliminar: arrestos por cada 100.000 habitantes, 2018

Al combinar los arrestos de diciembre de 2018 con la población de cada distrito (obtenida mediante web scraping), se obtiene una primera tasa normalizada. El Bronx presenta la tasa más alta de arrestos por cada 100.000 habitantes, seguido de Manhattan y Staten Island, mientras que Brooklyn y Queens, que son los distritos con mayor número absoluto de arrestos o de población presentan las tasas más bajas una vez normalizadas por población. Este resultado ilustra por qué el proyecto evita basar el diagnóstico únicamente en cifras absolutas.

Distrito	Arrestos	Población 2018	Arrestos / 100.000 hab.
Bronx	215	1.432.000	15,01
Brooklyn	237	2.583.000	9,18
Manhattan	209	1.629.000	12,83
Queens	206	2.279.000	9,04
Staten Island	50	476.000	10,50

Es importante aclarar que, a la fecha de esta entrega, el archivo de vehículos no incluye información de distrito (borough), por lo cual no fue posible calcular tasas de siniestralidad vial normalizadas por población; esta limitación quedó registrada explícitamente en la tabla de disponibilidad del cuaderno de integración (`hay_siniestros_por_distrito = False` para los cinco distritos) y se documenta también en la sección 5 de este informe.

5. Reporte de calidad de datos

Antes de realizar la integración definitiva se llevó a cabo una auditoría inicial de calidad de los conjuntos de datos.

La auditoría considera tres problemas principales:

1. Valores faltantes.
2. Registros duplicados.
3. Registros con claves repetidas, pero atributos diferentes.

Los resultados numéricos definitivos serán incorporados a partir de los resultados obtenidos directamente en el clúster.

5.1 Valores faltantes

Se realizó un análisis de valores faltantes para las variables de los diferentes conjuntos de datos utilizados en el proyecto.

Para cada conjunto de datos, arrestos, vehículos y pobreza, se identificó el número de valores faltantes por variable, el total de registros y el porcentaje de faltantes. Las variables se ordenaron de mayor a menor porcentaje de ausencia y se reportaron únicamente aquellas que presentaban al menos un valor faltante. Las demás se consideraron completas.

Conjunto	Registros	Variables	Completas	Con faltantes	Mayor %	Variable con mayor porcentaje
Arrestos	917	19	16	3	0,33 %	pd_desc, ky_cd, ofns_desc
Vehículos	4.551.002	25	5	20	99,32 %	public_property_damage_type
Pobreza	68.273	61	53	8	55,01 %	eng

En el conjunto de datos de arrestos, únicamente tres variables presentan valores faltantes: *pd_desc*, *ky_cd* y *ofns_desc*, con 3 registros faltantes cada una, equivalentes al 0,33 % del total. Las variables asociadas con fecha, distrito, precinto, coordenadas y características demográficas se encuentran completas. Por esta razón, los valores faltantes identificados no afectan de manera significativa los conteos territoriales de arrestos utilizados en el análisis.

En el conjunto de vehículos, 20 de las 25 variables presentan algún grado de ausencia. Sin embargo, los identificadores, la fecha y la hora están completos, lo que permite mantener la vinculación de los registros con los choques y realizar agregaciones temporales. Las variables *vehicle_model* con 98,7 % y *public_property_damage_type* con 99,3 % presentan una proporción de faltantes cercana a la totalidad de los registros, por lo que su utilidad analítica es limitada.

Las variables *vehicle_damage_1*, *vehicle_damage_2* y *vehicle_damage_3* presentan porcentajes de ausencia del 60,0 %, 69,5 % y 76,2 %, respectivamente. Este comportamiento

puede estar relacionado con campos que solo se diligencian cuando se registran varias zonas de daño en el vehículo. Por esta razón, una parte de estos valores podría corresponder a situaciones en las que el atributo no aplica.

Por otra parte, variables como *vehicle_make*, *vehicle_year*, *driver_sex* y los atributos relacionados con la licencia presentan entre aproximadamente 43 % y 54 % de valores faltantes. En consecuencia, cualquier análisis que utilice estas características estaría basado únicamente en una fracción del total de registros y deberá interpretarse teniendo en cuenta esta limitación. En contraste, *state_registration* con 8,1 %, *vehicle_type* con 6,2 % y *contributing_factor_1* con 3,7 % conservan una cobertura considerablemente mayor.

En el conjunto de datos relacionado con pobreza, 8 de las 61 variables presentan valores faltantes: *eng* con 55,0 %, *jwtr* con 51,2 %, *wkw* con 46,0 %, *esr* con 17,3 %, *msh* con 16,1 %, *lanx* con 5,2 %, *schl* con 3,1 % y *educattain* con 3,1 %. La distribución de estos valores es consistente con variables cuya aplicación depende de la edad, la situación laboral u otras características de la persona encuestada. Por esta razón, una parte importante de los valores ausentes puede representar casos en los que la pregunta no era aplicable y no necesariamente errores de captura. Las variables utilizadas para determinar la condición de pobreza se encuentran completas.

Los patrones anteriores justifican un tratamiento diferenciado de los valores faltantes según la naturaleza de cada variable y su función dentro del análisis.

Los valores faltantes no serán imputados de manera automática. Su tratamiento dependerá de la variable analizada y del indicador o procedimiento en el que participe. Un registro con un valor faltante en una determinada característica puede continuar siendo válido para otros análisis en los que dicha variable no sea necesaria.

Por ejemplo, un registro de arresto que carezca de información en una variable descriptiva puede continuar contribuyendo al conteo territorial de arrestos siempre que disponga de información válida sobre la fecha y la ubicación del evento.

En consecuencia, se conservarán los registros que contengan la información necesaria para cada indicador y se aplicarán tratamientos específicos únicamente cuando los valores faltantes impidan realizar un cálculo o análisis determinado.

5.2 Registros duplicados

Se identificaron registros completamente duplicados, es decir, observaciones que presentan los mismos valores en todas sus variables. Cuando se confirme que corresponden a duplicaciones exactas de una misma observación, se conservará una única ocurrencia.

Esta transformación permite reducir el tamaño innecesario de los datos y evita que una misma observación sea contabilizada varias veces durante las agregaciones.

5.3 Registros con claves conflictivas

También se identificaron casos en los que diferentes registros presentan la misma clave de identificación, pero contienen valores diferentes en uno o más atributos. Estos registros representan un problema diferente al de los duplicados exactos, debido a que no es posible determinar automáticamente cuál de las versiones corresponde al registro correcto.

Por esta razón, los registros conflictivos serán excluidos de las agregaciones analíticas cuando no exista información suficiente para resolver la inconsistencia.

La cantidad de registros afectados será reportada para determinar qué proporción representan sobre el total de cada conjunto de datos y verificar que su exclusión no tenga un impacto sustancial sobre el análisis.

5.4 Validación de los factores de ponderación

En los datos de pobreza se realizó una revisión específica de la variable PWGTP.

Los registros con valores nulos, iguales a cero o negativos fueron identificados y excluidos de las agregaciones ponderadas utilizadas para estimar población.

Los registros con valores faltantes en otras variables no serán eliminados automáticamente si contienen información útil para otros componentes del análisis.

6. Planteamiento de preguntas sobre los datos

A partir del objetivo de negocio y de los hallazgos obtenidos durante la exploración inicial de las fuentes, se plantean las siguientes preguntas de negocio. Estas preguntas orientarán las etapas posteriores de preparación, análisis y modelado de los datos y serán respondidas durante la entrega final del proyecto.

Seguridad pública

1. ¿Cómo se distribuyen los arrestos por territorio y período durante el año disponible?
2. ¿Cómo cambia la composición de las categorías de arresto entre territorios y períodos?

Seguridad vial

3. ¿Qué combinaciones de día de la semana y franja horaria concentran mayor número de colisiones?
4. ¿Qué tipos de vehículos aparecen con mayor frecuencia en las colisiones?
5. ¿Qué factores contribuyentes son reportados con mayor frecuencia y cómo varían según el tipo de vehículo?
6. ¿Qué diferencias existen entre colisiones con un solo vehículo registrado y aquellas con múltiples vehículos?

Socioeconómico

7. ¿Cómo se relacionan los indicadores territoriales de pobreza y educación con los indicadores de seguridad disponibles?
8. ¿Cómo cambian los indicadores territoriales de seguridad cuando se normalizan por población?

Clima

9. ¿Existe una asociación entre las condiciones meteorológicas y la frecuencia o características de las colisiones?

7. Filtros, limpieza y transformación inicial

Durante esta primera etapa se realizaron diferentes procesos de preparación de los datos con el objetivo de garantizar que las fuentes puedan ser utilizadas posteriormente para construir indicadores territoriales comparables. Este apartado documenta las transformaciones ejecutadas y planeadas para realizar posteriormente, la política aplicada en cada caso y las cifras resultantes. Todos los controles de calidad se generan dentro del pipeline y se almacenan en archivos JSON en la carpeta resultados/, de modo que cada cifra se puede observar cuando se necesite.

7.1 Eliminación de duplicados exactos

Los registros completamente duplicados serán reducidos a una única observación. Esta transformación busca evitar que una misma observación sea contabilizada más de una vez y disminuir el volumen innecesario de información procesada por el clúster.

7.2 Tratamiento de registros conflictivos

Cuando una misma clave de identificación aparece asociada con diferentes valores en sus atributos y no existe información suficiente para determinar cuál registro es correcto, los casos serán excluidos de los análisis correspondientes. Esta decisión busca evitar que inconsistencias de identificación generen resultados artificiales en las agregaciones.

7.3 Tratamiento de valores faltantes

No se aplicará una imputación general de los valores faltantes. La estrategia será conservar los registros que continúen siendo útiles para el análisis y realizar tratamientos específicos dependiendo de la variable. De esta manera, la ausencia de un dato en una variable no implica necesariamente eliminar todo el registro.

7.4 Tratamiento de PWGTP

Para los análisis ponderados de pobreza se validará la variable PWGTP. Los registros con valores nulos, iguales a cero o negativos serán excluidos de las agregaciones ponderadas debido a que no permiten realizar adecuadamente la estimación de población representada. La población y los indicadores de pobreza se calcularán utilizando los factores de ponderación válidos.

7.5 Filtro de edad para educación

Para el análisis del nivel educativo se considerará la población de 25 años o más. El objetivo de este filtro es obtener una población en la que el nivel educativo alcanzado sea más comparable, evitando incorporar personas que todavía se encuentran en etapas normales de escolarización.

7.6 Identificación de accidentes mediante COLLISION_ID

Debido a que el dataset de Motor Vehicle Collisions registra vehículos y no directamente accidentes, la cantidad de colisiones se calculará mediante identificadores únicos de colisión. De esta manera, una colisión que involucre varios vehículos será contabilizada como un único evento.

7.7 Normalización territorial

Como parte de las transformaciones posteriores se plantea normalizar los indicadores absolutos utilizando la población correspondiente a cada distrito.

Por ejemplo:

- En diciembre de 2018 Brooklyn registró el mayor número de arrestos de la ciudad (237) y Staten Island el menor (50). Brooklyn parecería el territorio con mayor actividad policial, con casi cinco veces los arrestos de Staten Island. Al normalizar por población, el ordenamiento cambia de bastante, el Bronx pasa a encabezar la tasa, con 15,01 arrestos por cada 100.000 habitantes, frente a 9,18 de Brooklyn. La razón es que el Bronx es el segundo distrito con menor población y concentra una alta proporción de arrestos sobre una base poblacional pequeña.

Esta transformación permitirá comparar territorios de diferentes tamaños poblacionales.

7.8 Integración de los conjuntos de datos

Una vez finalizada la limpieza individual de cada fuente, se realizará una agregación territorial por borough.

El resultado esperado será una tabla consolidada que reúna, para cada distrito, los principales indicadores de:

- Seguridad pública.
- Seguridad vial.
- Pobreza.
- Educación.
- Población.

Esta tabla constituirá la base para el diagnóstico territorial y para la formulación posterior del plan de acción.

8. Desarrollo de los bonos

Adicionalmente a los cuatro cuadernos principales, el equipo desarrolló tres cuadernos de bono: dos fuentes alternativas para la población de los distritos (usadas para construir el denominador de las tasas territoriales) y una consulta a una API externa de datos climáticos. A continuación, se documenta el desarrollo de cada uno y los resultados obtenidos.

8.1 Bono 1 - Web scraping de población por distrito (05_Bono_Scraper.ipynb)

Este cuaderno obtiene, mediante web scraping, la población de los cinco distritos de Nueva York para 2018, mismo dato utilizado como denominador para calcular la tasa de arrestos por cada 100.000 habitantes en la sección 4.8 de este informe.

El proceso consistió en descargar el archivo JavaScript que controla la tabla de población del portal NYC Data de Baruch College (baruch.cuny.edu/nycdata), localizar mediante una expresión regular la ruta del CSV real que alimenta esa tabla, descargar dicho CSV, y extraer únicamente la sección correspondiente a la ciudad de Nueva York (“NYC”) y a la columna del año 2018. Los nombres de los distritos en la fuente original (por ejemplo “Brooklyn (Kings)” o “Manhattan (New York)”) se tradujeron a los nombres estándar usados en el resto del proyecto, y las cifras, reportadas en miles de habitantes, se multiplicaron por 1.000. Antes de guardar el resultado se validó que existieran exactamente cinco distritos, sin valores nulos, cero o negativos.

El resultado se guardó en poblacion_nyc_2018.csv, dentro de la carpeta de resultados compartida, para ser reutilizado directamente por el cuaderno de integración (04_Integracion_Preguntas.ipynb).

Distrito	Población 2018 (scraping)
Bronx	1.432.000
Brooklyn	2.583.000
Manhattan	1.629.000
Queens	2.279.000
Staten Island	476.000

8.2 Bono 2 - Fuente alterna de población vía portal de datos abiertos (01_Bono_NYHealth.ipynb)

Como segunda fuente de población, se identificó en el portal oficial Health Data NY (health.data.ny.gov) el dataset “New York State Population Data: Beginning 2003”, publicado por el New York State Department of Health, que reporta población por county, año, grupo de edad, género y raza/etnia.

Se descargó el archivo completo del portal (236.340 registros, 12,8 MB) mediante una petición HTTP directa a su API pública, y se filtró únicamente a los cinco counties que conforman la ciudad de Nueva York (Bronx, Kings, New York, Queens y Richmond), usando la correspondencia oficial entre counties y distritos (boroughs). Del resultado (18.180 registros) se conservaron solo los valores “Total” de edad, género y raza/etnia para el año 2018, obteniendo así la población total por distrito sin desagregar. Se verificó además que no quedaran valores faltantes ni registros duplicados, y que se obtuvieran exactamente los cinco distritos esperados.

Distrito	Población 2018 (Health Data NY)
Brooklyn	2.582.830
Queens	2.278.906
Manhattan	1.628.701
Bronx	1.432.132
Staten Island	476.179

Estas cifras son consistentes con las obtenidas mediante el scraping del Bono 1 (diferencias menores al 0,01% en todos los distritos), lo cual sirve como validación cruzada del denominador poblacional usado en las tasas territoriales del proyecto.

8.3 Bono 3 - Consulta climática mediante API externa (02_Bono_ClimaAPI.ipynb)

Como prueba de concepto para la dimensión climática mencionada en la sección 2.5, se implementó una consulta a la Historical Weather API de Open-Meteo para los cinco distritos de la ciudad de Nueva York: Manhattan, Brooklyn, Queens, Bronx y Staten Island. Esta API es pública y no requiere llave. Se eligió en lugar de OpenWeatherMap porque el plan gratuito de este último solo entrega la condición actual y el pronóstico de los próximos días, sin datos históricos, mientras que el diagnóstico del proyecto se centra en 2018.

Se realizaron cinco llamadas, una por distrito, al endpoint `/v1/archive`, solicitando las variables diarias de todo 2018: 365 días por distrito y 1.825 registros en total, muy por debajo de los límites de uso gratuito. Las respuestas en JSON se guardaron localmente, junto con la fecha de consulta y las variables solicitadas, para no volver a consultar la API.

A partir de los datos diarios se construyeron resúmenes semanales (de lunes a domingo, con 52 semanas completas y una semana 53 que solo tiene el 31 de diciembre), mensuales y anuales por distrito. Cada resumen incluye la temperatura media, mínima y máxima, la precipitación y la nevada acumuladas, y el número de días de lluvia (al menos 1 mm) y de nieve (al menos 1 cm).

Es importante aclarar una limitación de este bono. Los datos de Open-Meteo son de reanálisis, es decir, modelos que combinan estaciones, satélites y radares, y no mediciones de una estación en cada distrito. Su resolución espacial es de entre 9 y 25 km, por lo que distritos cercanos pueden caer en la misma celda de la malla y mostrar valores idénticos o casi idénticos. El cuaderno verifica esta situación: muestra la celda usada para cada distrito, identifica los pares con series de temperatura idénticas y calcula la mayor diferencia mensual de temperatura entre distritos. Por lo tanto, la comparación entre distritos es aproximada y los resultados representan el clima general de la ciudad, no las condiciones locales de cada distrito.

A diferencia de una consulta de pronóstico, los resultados corresponden a 2018, el año objetivo del diagnóstico histórico del proyecto, por lo que este bono ya permite incorporar la dimensión climática al análisis de ese año.

9. Conclusiones

La primera etapa del proyecto permitió establecer el contexto de negocio y definir la estrategia analítica necesaria para apoyar la toma de decisiones relacionadas con seguridad pública y seguridad vial en New York City. A partir del análisis inicial de las fuentes disponibles, se identificó que los indicadores de arrestos y colisiones requieren ser estudiados

desde una perspectiva territorial, integrando información de diferentes dimensiones como población, condiciones socioeconómicas y características propias de los eventos registrados.

El proceso de selección, preparación y exploración de los datos permitió reconocer la importancia de realizar transformaciones previas antes de generar conclusiones sobre el comportamiento de los territorios. En particular, se evidenció que los valores absolutos pueden generar interpretaciones incompletas, debido a que los distritos tienen diferentes tamaños poblacionales. Por esta razón, la construcción de indicadores normalizados será fundamental para realizar comparaciones más adecuadas entre los boroughs de New York City.

Asimismo, durante la revisión de calidad de los datos se identificaron retos asociados a valores faltantes, diferencias en las unidades de observación y limitaciones propias de las fuentes. Por ejemplo, en el caso de las colisiones fue necesario diferenciar entre registros de vehículos involucrados y cantidad real de accidentes mediante identificadores únicos de colisión, evitando así sobreestimar el indicador vial. De igual forma, se establecieron estrategias específicas de limpieza y transformación para conservar la información útil y garantizar la consistencia de los análisis posteriores.

Finalmente, esta entrega permitió construir la base metodológica y tecnológica para las siguientes fases del proyecto. La integración de los datos procesados mediante Spark permitirá avanzar hacia la identificación de patrones territoriales, relaciones entre variables y generación de recomendaciones fundamentadas en evidencia. Los resultados obtenidos en la etapa final estarán orientados a responder las preguntas de negocio planteadas y aportar criterios para la focalización de posibles intervenciones públicas.

10. Referencias

Corredor, J. (2026). Conceptos Big Data Metodología Crisp DM [Presentación]. Pontificia Universidad Javeriana.

Corredor, J. (2024). Big Data [Presentación]. Pontificia Universidad Javeriana.

Mayor's Office for Economic Opportunity. (Mayo, 2022). NYCgov poverty measure data (2018) [Conjunto de datos]. NYC Open Data. Recuperado el 2 de octubre de 2026 de https://data.cityofnewyork.us/City-Government/NYCgov-Poverty-Measure-Data-2018-cts7-vksw/about_data

New York City Police Department. (Julio, 2026). NYPD arrest data (year to date) [Conjunto de datos]. NYC OpenData. Recuperado el 2 de octubre de 2026 de https://data.cityofnewyork.us/Public-Safety/NYPD-Arrest-Data-Year-to-Date-/uip8-fykc/about_data

New York City Police Department. (Julio, 2026). Motor vehicle collisions - vehicles [Conjunto de datos]. NYC OpenData. Recuperado el 2 de octubre de 2026 de https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Vehicles/bm4k-52h4/about_data

New York State Department of Health. (Abril, 2025). New York State population data: Beginning 2003 [Conjunto de datos]. Health Data NY. Recuperado el 2 de octubre de 2026 de https://health.data.ny.gov/Health/New-York-State-Population-Data-Beginning-2003/e9uj-s3sf/about_data

Open-Meteo. (s. f.). Free weather API [Servicio web de datos]. Recuperado el 2 de octubre de 2026 de <https://open-meteo.com/>

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (pp. 29–39). Practical Application Company.