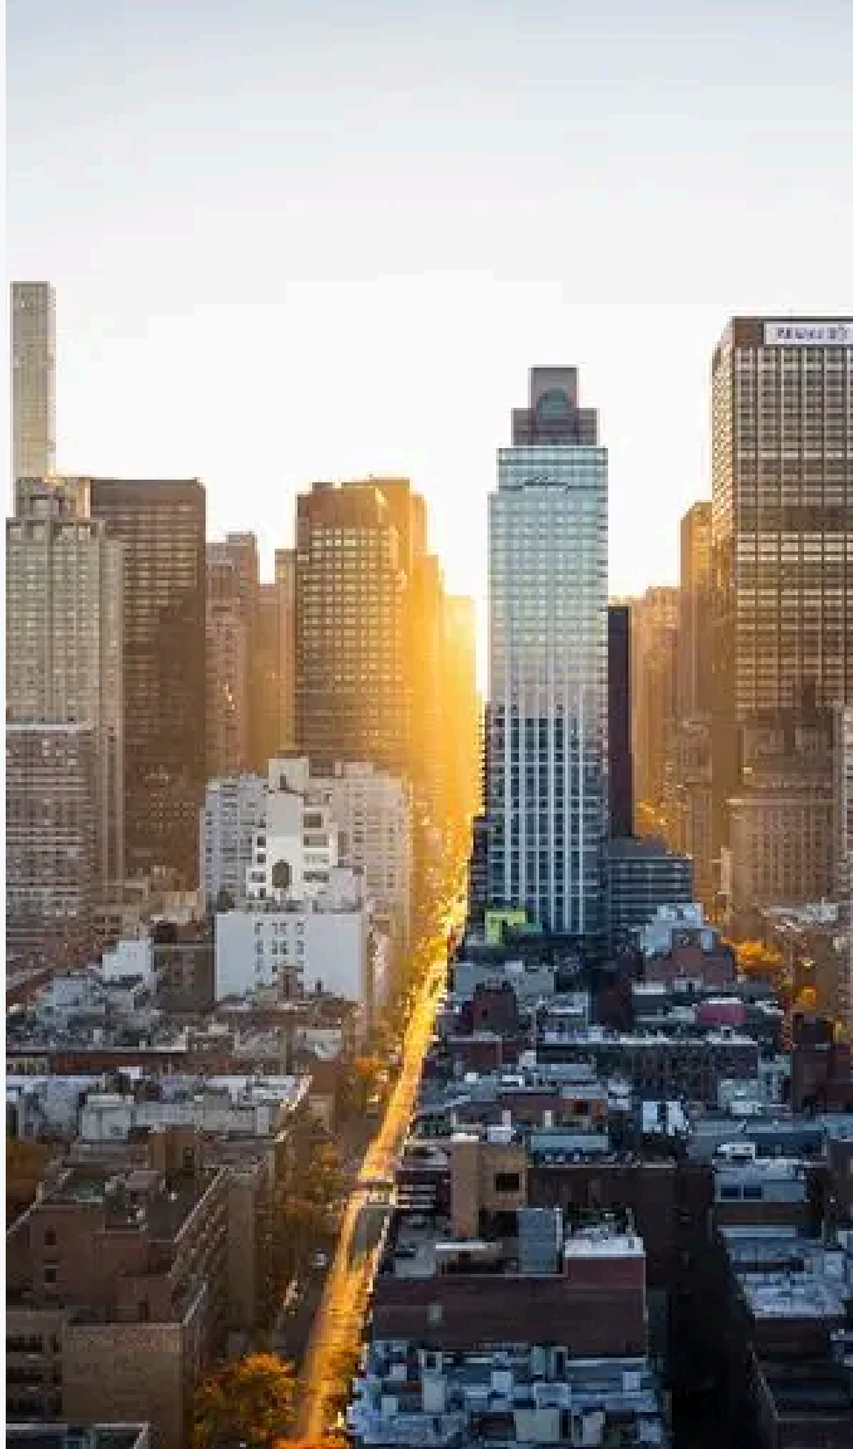
Diagnóstico territorial de New York City 2018: arrestos y siniestralidad vial

Entendimiento del negocio, preparación y exploración de los datos

Gabriel Jaramillo, Juan Felipe Gómez, David Felipe Vargas, Sara Pulgarín y Juan Camilo Delgado



El objetivo es focalizar las intervenciones de seguridad pública y vial en los 5 distritos, con indicadores normalizados por población y contexto socioeconómico.

8,48 M

habitantes en 5 distritos

30.179

colisiones en los primeros meses de 2026

+25%

de la población bajo la pobreza suplementaria

Objetivos analíticos

- Patrones Espacio-Temporales: Identificar zonas y periodos críticos con concentraciones atípicas de arrestos y colisiones.
- Relación Contextual: Evaluar la correlación entre seguridad urbana, pobreza y educación (sin asumir causalidad).
- Priorización Territorial: Establecer criterios cuantitativos basados en evidencia para definir zonas de atención urgente.
- Plan de Acción y KPIs: Formular recomendaciones operativas de gestión pública y métricas de seguimiento.

Cinco fuentes para tres dimensiones

Fuente	Unidad de observación	Aporta
Arrestos NYPD	Un arresto	Seguridad pública
Motor Vehicle Collisions - Vehicles	Un vehículo	Seguridad vial
NYCgov Proverty Measure	Persona de la muetsra, con peso PWGTP	Pobreza y educación
Población 2018 (scraping y Health Data NY)	Distrito	Denominador de tasas
Clima (exploratoria)	Día	Contexto de colisiones

Año base 2018: es el que tiene información socioeconómica y poblacional compatible.

Procesamiento en un clúster Apache Spark propio

6

workers, 4 núcleos cada uno (máx. 2 por aplicación)

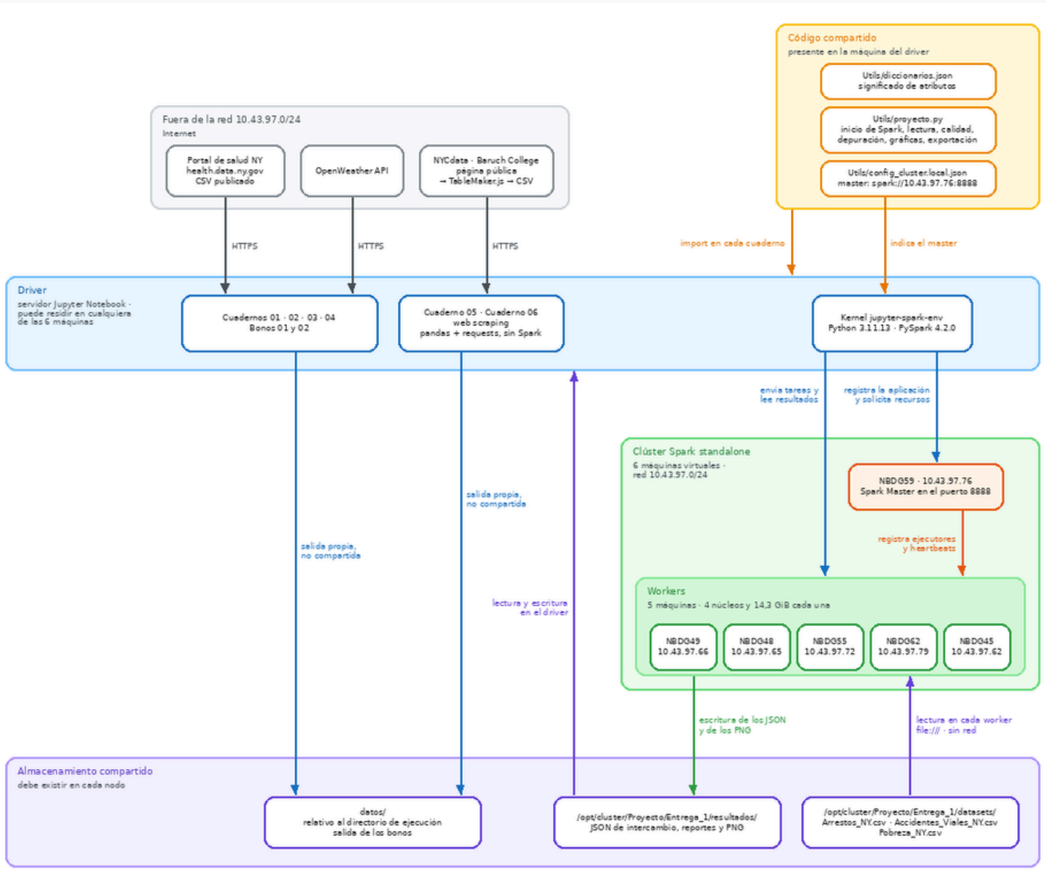
86 GiB

de memoria total (14,3 GiB por worker)

4.2.0

Spark y PySpark, con Python 3.11 en Jupyter

Conjunto	Registros	Variables
Arrestos	Un arresto	Seguridad pública
Motor Vehicle Collisions - Vehicles	Un vehículo	Seguridad vial
NYCgov Proverty Measure	Persona de la muetsra, con peso PWGTP	Pobreza y educación


Código compartido
presente en la maquina del driver
Utils/diccionarios.json
significado de atributos
Utils/proyecto.py
inicio de Spark, lectura, calidad, depuración, gráficas, exportación
Utils/config_cluster.local.json
master: spark://10.43.97.76:8888
Fuera de la red 10.43.97.0/24
Internet
Portal de salud NY
health.data.ny.gov
CSV publicado
OpenWeather API
NYCdata · Baruch College
página pública
→ TableMaker.js → CSV
HTTPS
HTTPS
HTTPS
import en cada cuaderno
indica el master
Driver
servidor Jupyter Notebook · puede residir en cualquiera de las 6 maquinas
Cuadernos 01 · 02 · 03 · 04
Bonos 01 y 02
Cuaderno 05 · Cuaderno 06
web scraping
pandas + requests, sin Spark
Kernel jupyter-spark-env
Python 3.11.13 · PySpark 4.2.0
envía tareas y lee resultados
registra la aplicación y solicita recursos
Clúster Spark standalone
6 maquinas virtuales · red 10.43.97.0/24
NBD059 · 10.43.97.76
Spark Master en el puerto 8888
registra ejecutores y heartbeats
Workers
5 maquinas · 4 núcleos y 14,3 GiB cada una
NBD049
10.43.97.66
NBD048
10.43.97.65
NBD055
10.43.97.72
NBD062
10.43.97.79
NBD045
10.43.97.62
salida propia, no compartida
salida propia, no compartida
lectura y escritura en el driver
escritura de los JSON y de los PNG
lectura en cada worker file:// · sin red
Almacenamiento compartido
debe existir en cada nodo
datos/
relativo al directorio de ejecución
salida de los bonos
/opt/cluster/Proyecto/Entrega_1/resultados/
JSON de intercambio, reportes y PNG
/opt/cluster/Proyecto/Entrega_1/datasets/
Arrestos_NY.csv · Accidentes_Viales_NY.csv
Pobreza_NY.csv

Al normalizar por población cambia el ordenamiento

Distrito	Arrestos dic. 2018	Por 100.000 hab.	Pobreza	Sin secundaria (25+)
Bronx	215	15,01	27,10%	26,26%
Brooklyn	237	9,18	20,31%	16,42%
Manhattan	209	12,83	15,06%	11,67%
Queens	206	9,04	17,02%	17,32%
Staten Island	50	10,50	16,00%	12,17%

Brooklyn lidera en cifras absolutas; el Bronx lidera en tasa y también en pobreza y rezago educativo.

Calidad de datos: tres problemas, tres políticas

Duplicados

Registros idénticos: se conserva una sola ocurrencia.

Claves en conflicto

Misma clave, atributos distintos: se excluyen de las agregaciones.

PWGTP ≤ 0 o nulo

No sirve para ponderar: se excluye de los cálculos de población.

Faltantes: sin imputación general. El factor contribuyente tiene 49,3% "Unspecified" y 4,1% vacío, así que se trata variable por variable.

Nueve preguntas para la entrega final

- Arrestos por territorio y período
- Composición de categorías de arresto
- Día y franja horaria con más colisiones
- Tipos de vehículo más frecuentes
- Factores contribuyentes por tipo de vehículo
- Colisiones de un vehículo vs. múltiples
- Pobreza y educación vs. seguridad
- Indicadores normalizados por población
- Clima y colisiones

features importantes - planteamiento inicial

Integración y geolocalización

- **ARREST_BORO** (Dataset de Arrestos)
- **BOROUGH y ZIP CODE** (Dataset de Colisiones)
- **Boro** (Dataset de Pobreza)
- **ARREST_PRECINCT / Coordenadas** (Dataset de arrestos)

Metricas de intensidad e impacto

Seguridad y actividad policial

LAW_CAT_CD y OFNS_DESC / PD_DESC (Gravedad y descripción del delito)

Siniestralidad vial

NUMBER OF PERSONS INJURED y KILLED

Variables socioeconómicas

Pobreza

NYCgov_Income y NYCgov_Threshold

NYCgov_Pov_Stat (tasa de pobreza real)

EST_MOOP (Gastos médicos de bolsillo)

DIS / DS (Indicador de discapacidad en el hogar)

Variables temporales

Arrestos y accidentes

ARREST_DATE / ACCIDENT_DATE y ACCIDENT_TIME

Creación de variables que permitan responder preguntas de estacionalidad y patrones horarios

Transformaciones iniciales y próximos pasos

Ya aplicado

- Colisiones por COLLISION_ID único
- Tasa de arrestos por 100.000 hab.
- Educación solo en 25+ años
- Población validada con dos fuentes (diferencia < 0,01%)

Antes de la entrega final

- Arrestos de los 12 meses de 2018
- Distrito en el archivo de vehículos
- Clima histórico de 2018 (Open-Meteo)
- Tabla integrada por distrito y plan de acción

Referencias

- Corredor, J. (2026). Conceptos Big Data Metodología Crisp DM [Presentación]. Pontificia Universidad Javeriana.
- Corredor, J. (2024). Big Data [Presentación]. Pontificia Universidad Javeriana.
- Mayor's Office for Economic Opportunity. (Mayo, 2022). NYCgov poverty measure data (2018) [Conjunto de datos]. NYC Open Data. Recuperado el 2 de octubre de 2026 de https://data.cityofnewyork.us/City-Government/NYCgov-Poverty-Measure-Data-2018-/cts7-vksw/about_data
- New York City Police Department. (Julio, 2026). NYPD arrest data (year to date) [Conjunto de datos]. NYC OpenData. Recuperado el 2 de octubre de 2026 de https://data.cityofnewyork.us/Public-Safety/NYPD-Arrest-Data-Year-to-Date-/uip8-fykc/about_data

Referencias

- New York City Police Department. (Julio, 2026). Motor vehicle collisions - vehicles [Conjunto de datos]. NYC OpenData. Recuperado el 2 de octubre de 2026 de https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Vehicles/bm4k-52h4/about_data
- New York State Department of Health. (Abril, 2025). New York State population data: Beginning 2003 [Conjunto de datos]. Health Data NY. Recuperado el 2 de octubre de 2026 de https://health.data.ny.gov/Health/New-York-State-Population-Data-Beginning-2003/e9uj-s3sf/about_data
- Open-Meteo. (s. f.). Free weather API [Servicio web de datos]. Recuperado el 2 de octubre de 2026 de https://open-meteo.com/
- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (pp. 29–39). Practical Application Company.



Gracias

¿Preguntas u observaciones?