


# Diagnóstico territorial de New York City 2018: arrestos y sinistralidad vial

Entendimiento del negocio, preparación y  
exploración de los datos

---

Gabriel Jaramillo, Juan Felipe Gómez, David Felipe  
Vargas, Sara Pulgarín y Juan Camilo Delgado



El objetivo es focalizar las intervenciones de seguridad pública y vial en los 5 distritos, con indicadores normalizados por población y contexto socioeconómico.

**8,48 M**

habitantes en 5 distritos

**30.179**

colisiones en los primeros  
meses de 2026

**+25%**

de la población bajo la  
pobreza suplementaria

# Cinco fuentes para tres dimensiones

| Fuente                                      | Unidad de observación                 | Aporta                 |
|---------------------------------------------|---------------------------------------|------------------------|
| Arrestos NYPD                               | Un arresto                            | Seguridad pública      |
| Motor Vehicle Collisions - Vehicles         | Un vehículo                           | Seguridad vial         |
| NYCgov Proverty Measure                     | Persona de la muetsra, con peso PWGTP | Pobreza y educación    |
| Población 2018 (scrapping y Health Data NY) | Distrito                              | Denominador de tasas   |
| Clima (exploratoria)                        | Día                                   | Contexto de colisiones |

Año base 2018: es el que tiene información socioeconómica y poblacional compatible.

# Procesamiento en un clúster Apache Spark propio

6

workers, 4 núcleos cada uno (máx. 2 por aplicación)

86 GiB


de memoria total (14,3 GiB por worker)

4.2.0

Spark y PySpark, con Python 3.11 en Jupyter

| Conjunto                            | Registros                             | Variables           |
|-------------------------------------|---------------------------------------|---------------------|
| Arrestos (dic. 2018)                | Un arresto                            | Seguridad pública   |
| Motor Vehicle Collisions - Vehicles | Un vehículo                           | Seguridad vial      |
| NYCgov Proverty Measure             | Persona de la muetsra, con peso PWGTP | Pobreza y educación |

# Diagrama de despliegue



# Al normalizar por población cambia el ordenamiento

| Distrito      | Arrestos dic. 2018 | Por 100.000 hab. | Pobreza | Sin secundaria (25+) |
|---------------|--------------------|------------------|---------|----------------------|
| Bronx         | 215                | 15,01            | 27,10%  | 26,26%               |
| Brooklyn      | 237                | 9,18             | 20,31%  | 16,42%               |
| Manhattan     | 209                | 12,83            | 15,06%  | 11,67%               |
| Queens        | 206                | 9,04             | 17,02%  | 17,32%               |
| Staten Island | 50                 | 10,50            | 16,00%  | 12,17%               |

Brooklyn lidera en cifras absolutas; el Bronx lidera en tasa y también en pobreza y rezago educativo.

# Calidad de datos: tres problemas, tres políticas

## Duplicados

Registros idénticos: se conserva una sola ocurrencia.

## Claves en conflicto

Misma clave, atributos distintos: se excluyen de las agregaciones.

## $PWGTP \leq 0$ o nulo

No sirve para ponderar: se excluye de los cálculos de población.

Faltantes: sin imputación general. El factor contribuyente tiene 49,3% "Unspecified" y 4,1% vacío, así que se trata variable por variable.

# Nueve preguntas para la entrega final

**Arrestos por territorio y período**

**Composición de categorías de arresto**

**Día y franja horaria con más colisiones**

**Tipos de vehículo más frecuentes**

**Factores contribuyentes por tipo de vehículo**

**Colisiones de un vehículo vs. múltiples**

**Pobreza y educación vs. seguridad**

**Indicadores normalizados por población**

**Clima y colisiones**

# Transformaciones iniciales y próximos pasos

## Ya aplicado

- Colisiones por COLLISION\_ID único
- Tasa de arrestos por 100.000 hab.
- Educación solo en 25+ años
- Población validada con dos fuentes (diferencia < 0,01%)

## Antes de la entrega final

- Arrestos de los 12 meses de 2018
- Distrito en el archivo de vehículos
- Clima histórico de 2018 (Open-Meteo)
- Tabla integrada por distrito y plan de acción

# Referencias

- Corredor, J. (2026). Conceptos Big Data Metodología Crisp DM [Presentación]. Pontificia Universidad Javeriana.
- Corredor, J. (2024). Big Data [Presentación]. Pontificia Universidad Javeriana.
- Mayor's Office for Economic Opportunity. (Mayo, 2022). NYCgov poverty measure data (2018) [Conjunto de datos]. NYC Open Data. Recuperado el 2 de octubre de 2026 de [https://data.cityofnewyork.us/City-Government/NYCgov-Poverty-Measure-Data-2018-/cts7-vksw/about\\_data](https://data.cityofnewyork.us/City-Government/NYCgov-Poverty-Measure-Data-2018-/cts7-vksw/about_data)
- New York City Police Department. (Julio, 2026). NYPD arrest data (year to date) [Conjunto de datos]. NYC OpenData. Recuperado el 2 de octubre de 2026 de [https://data.cityofnewyork.us/Public-Safety/NYPD-Arrest-Data-Year-to-Date-/uip8-fykc/about\\_data](https://data.cityofnewyork.us/Public-Safety/NYPD-Arrest-Data-Year-to-Date-/uip8-fykc/about_data)

# Referencias

- New York City Police Department. (Julio, 2026). Motor vehicle collisions - vehicles [Conjunto de datos]. NYC OpenData. Recuperado el 2 de octubre de 2026 de [https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Vehicles/bm4k-52h4/about\\_data](https://data.cityofnewyork.us/Public-Safety/Motor-Vehicle-Collisions-Vehicles/bm4k-52h4/about_data)
- New York State Department of Health. (Abril, 2025). New York State population data: Beginning 2003 [Conjunto de datos]. Health Data NY. Recuperado el 2 de octubre de 2026 de [https://health.data.ny.gov/Health/New-York-State-Population-Data-Beginning-2003/e9uj-s3sf/about\\_data](https://health.data.ny.gov/Health/New-York-State-Population-Data-Beginning-2003/e9uj-s3sf/about_data)
- Open-Meteo. (s. f.). Free weather API [Servicio web de datos]. Recuperado el 2 de octubre de 2026 de <https://open-meteo.com/>
- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining (pp. 29–39). Practical Application Company.

An aerial view of the New York City skyline, featuring the Freedom Tower as the central focus. The image is overlaid with a semi-transparent grey filter. The text 'Gracias' is centered in a large, dark blue font, with a horizontal orange line underneath it. Below the line, the text '¿Preguntas u observaciones?' is displayed in a smaller, dark blue font.

# Gracias

¿Preguntas u observaciones?