

# Informe del taller de introducción a Apache Spark

Gabriel Jaramillo Cuberos  
Procesamiento de Datos

Septiembre, 2026

## 1. Objetivo

Configurar un entorno de trabajo con Jupyter y Apache Spark, y desarrollar un flujo de clasificación sobre el conjunto de datos Iris utilizando las herramientas de aprendizaje automático de PySpark.

## 2. Entorno de trabajo

Se utilizó una máquina virtual Linux con un servidor Jupyter, accesible desde el navegador mediante un túnel SSH. La sesión de Spark se conectó a un clúster con arquitectura master-worker.

Durante la configuración se alinearon Python 3.11 y PySpark/Spark 4.2.0. También se verificaron las dependencias del notebook y la disponibilidad de NumPy en los procesos Python de los workers.

La aplicación se configuró con un máximo de dos núcleos y un gigabyte de memoria por ejecutor, con el propósito de compartir los recursos del clúster con otros usuarios.

## 3. Procedimiento

El taller se desarrolló en las siguientes etapas:

1. **Carga y exploración:** lectura de `iris.csv`, compuesto por 150 registros, cuatro variables numéricas y una columna de especie. Se revisaron el esquema, los conteos y las estadísticas descriptivas.
2. **Preparación de etiquetas:** conversión de la columna `species` a una representación numérica mediante `StringIndexer`.
3. **Construcción de características:** agrupación de las medidas de sépalos y pétalos en un vector `DenseVector`, para obtener las columnas `label` y `features`.
4. **Escalado:** aplicación de `StandardScaler` para ajustar la escala de las características.
5. **División de datos:** separación aleatoria con proporciones objetivo de 90 % para entrenamiento y 10 % para prueba, utilizando la semilla 12345.
6. **Modelado y evaluación:** entrenamiento de un árbol de decisión, un Random Forest de diez árboles y un clasificador Naive Bayes multinomial. La evaluación se realizó mediante exactitud (*accuracy*).

## 4. Dificultades y soluciones

- **Configuración de Spark:** se corrigieron la dirección del master y la ruta del archivo `fairscheduler.xml`.
- **Acceso al CSV:** un worker no encontraba el archivo porque estaba almacenado únicamente en otra máquina. Se identificó la necesidad de disponer del mismo archivo en la misma ruta de los nodos que realizan la lectura, o utilizar almacenamiento compartido como HDFS.
- **Compatibilidad de Python:** los procesos Python de los workers utilizaban inicialmente Python 3.9. Se instaló y seleccionó Python 3.11 para ejecutar las operaciones distribuidas de PySpark.
- **Dependencias del entorno:** el cambio de kernel dejó en evidencia que las librerías pertenecen a entornos específicos. Se instalaron y verificaron las dependencias en el nuevo entorno y NumPy en el worker utilizado durante las pruebas.

## 5. Resultados

Las salidas guardadas en el cuaderno muestran los siguientes resultados:

| Modelo            | Exactitud en prueba |
|-------------------|---------------------|
| Árbol de decisión | 90.91 %             |
| Random Forest     | 100.00 %            |
| Naive Bayes       | 100.00 %            |

Random Forest y Naive Bayes obtuvieron una mayor exactitud que el árbol de decisión en la partición evaluada. Sin embargo, estos resultados corresponden a un conjunto de prueba pequeño y a una sola división de los datos; no permiten afirmar una superioridad general.

Además, el cuaderno ajusta el escalador antes de separar entrenamiento y prueba. Como mejora metodológica, este ajuste debería realizarse únicamente con los datos de entrenamiento y aplicarse posteriormente al conjunto de prueba, preferiblemente mediante un **Pipeline**.

## 6. Conclusiones

- Jupyter facilitó la ejecución y documentación del análisis desde una máquina virtual.
- La ejecución distribuida requiere coherencia entre versiones, dependencias, rutas de archivos y configuración de los equipos.
- Spark permitió practicar la preparación de datos y el entrenamiento de clasificadores en un clúster. Por el tamaño reducido de Iris, el taller demuestra el flujo de trabajo, pero no mide una ventaja de rendimiento frente a la ejecución local.
- La evaluación de modelos debe considerar la separación adecuada de los datos y pruebas adicionales antes de generalizar los resultados.

## 7. Archivos de entrega

- `Jaramillo_Gabriel_Tutorial_Apache_Spark.ipynb`: código, explicaciones y resultados del taller.
- `iris.csv`: conjunto de datos utilizado.
- `README.md`: descripción y guía breve del repositorio.